

新增成立的必要邊界

時間還原理論 4.0 對人工智慧學習效率問題的理論闡述

Necessary Boundaries of New Establishment:

A Time Restoration Theory 4.0 Account of Learning Efficiency in Artificial Intelligence

作者：非同一（ Σ - Ω ）

年份：2026

文件性質：正式跨領域理論研究稿

Document Type: Formal Cross-Disciplinary Theoretical Research Manuscript

DOI：10.5281/zenodo.22670346

摘要

人工智慧學習效率（**learning efficiency**）通常關注模型如何以較少資料、較低計算量、較少記憶體或較低訓練成本取得或維持能力。近期大型語言模型研究進一步把 **data efficiency**、**memory efficiency** 與 **compute efficiency** 視為相互關聯但不可混同的資源限制。本研究不提出新的資料選擇、模型壓縮、參數高效微調、訓練演算法或硬體方法，也不宣稱時間還原理論 4.0（**TRT 4.0**）可以直接降低 **FLOPs**、樣本數或能源消耗，而是以 **TRT 4.0** 所承接的表示再進入、結構同型、最低數量、必要層級與非封閉等關係，對「新增能力成立是否等於既有成立內容必須全部重新建立」進行跨領域理論映射。

本研究將學習效率的一個基礎理論問題重新表述為：當既有結構與表示已經成立並可重新進入後續生成時，新的生成位置若形成新的能力或判定，是否必須把所有既有成立內容再次作為新的最低必要成立條件。**TRT 4.0** 的最低數量命題區分最低必要量與實際存在總量；**Rep/Enter** 允許既有表示重新進入後續生成；**Iso** 允許指定結構在非同一位置重新成立；**Necessary Level** 則限制不同判定面向的成立不能互相偷渡。據此，本文提出：新增成立不等於全部重建。

此命題不等於「一個差異即可完成 AI 學習」，也不允許由 $N_{\min}^{\text{TRT}} = 1$ 推出單一樣本、單一 token、單一梯度步或固定最小算力足以產生能力。**TRT** 的最低數量判定處理已成立非同所需的最低差異數量，不是機器學習 **sample complexity**、**compute complexity** 或 **scaling law**。本文因此把「理論上的最低必要成立」與「工程上的最低資源需求」明確分離。

本研所得為 **TRT 4.0** 框架內的理論解釋與跨領域映射，不是學習效率的經驗證實。本文未進行模型訓練、資料削減實驗、**FLOP** 測量、記憶體評估、能耗比較、**sample-complexity** 證明或 **scaling-law** 推導。因此，本文不主張 **TRT** 已提高人工智慧學習效率，而是建立可供後續操作化與實證檢驗的判定問題：在新的能力形成時，哪些內容必須新增成立，哪些既有成立可被重新使用，而哪些資源節省仍須由工程方法另外證明。

關鍵詞：人工智慧學習效率；資料效率；計算效率；時間還原理論；**TRT 4.0**；最低數量；表示再進入；結構同型；必要層級；非封閉

Abstract

Learning efficiency in artificial intelligence commonly concerns how models acquire or preserve capabilities with less data, computation, memory, or training cost. Recent work on large language models further treats data efficiency, memory efficiency, and compute efficiency as related but non-identical resource constraints. This study does not propose a new data-selection method, compression technique, parameter-efficient fine-tuning procedure, training algorithm, or hardware optimization, and it does not claim that Time Restoration Theory 4.0 (TRT 4.0) directly

reduces FLOPs, sample counts, or energy consumption. Instead, it conducts a cross-disciplinary theoretical mapping using re-entry of representation, structural isomorphism, minimum quantity, necessary levels, and non-closure to examine whether the establishment of a new capability requires all previously established contents to be established again.

The problem is reformulated as follows: when prior structures and representations have already been established and can re-enter subsequent generation, does the establishment of a new capability or judgment at a new generative position require every prior establishment to become a new minimum necessary condition? TRT 4.0 distinguishes minimum necessary quantity from the total amount that may exist; Rep/Enter permits established representations to re-enter subsequent generation; Iso permits a specified structure to be re-established at a non-identical position; and Necessary Level prevents judgments at distinct levels from being transferred without qualification. On this basis, the paper proposes a concise theoretical formulation: new establishment does not equal total re-establishment.

This formulation does not mean that one TRT difference is sufficient for AI learning, nor does $N_{\min}^{\text{TRT}} = 1$ imply that one sample, one token, one gradient step, or any fixed minimum amount of compute is sufficient to acquire a capability. TRT minimum quantity concerns the minimum number of differences required to carry an already-established non-identity relation; it is not a machine-learning sample-complexity, compute-complexity, or scaling-law result. The study therefore separates theoretical minimum establishment from engineering resource requirements.

The results are theoretical interpretations and cross-disciplinary mappings within TRT 4.0, not empirical verification of learning efficiency. No model training, data-ablation experiment, FLOP measurement, memory evaluation, energy comparison, sample-complexity proof, or scaling-law derivation is provided. The paper therefore does not claim that TRT has improved AI learning efficiency; it establishes a judgment problem for later operationalization and empirical testing: which contents must be newly established when a new capability forms, which prior establishments may be reused, and which resource savings must still be demonstrated independently by engineering methods.

Keywords: learning efficiency; data efficiency; compute efficiency; Time Restoration Theory; TRT 4.0; minimum quantity; re-entry of representation; structural isomorphism; necessary level; non-closure

一、研究背景

人工智慧學習效率是一個多層次問題。對大型語言模型而言，效率可以涉及訓練資料利用、GPU 記憶體、計算預算、參數更新、訓練時間與推論成本。Schmidt 等人（2026）將 LLM 訓練效率整理為 data、memory 與 compute 三個相互耦合的限制，並指出不同資源預算下的最佳資料與計算

配置不必相同。Luo 等人（2025）則從 data-centric 角度整理 data-efficient LLM post-training，包括資料選擇、品質提升、合成資料、蒸餾與壓縮等方法。這些研究證明「如何以有限資源取得更多有效學習」是實際 AI 研究問題，但不構成 TRT 命題的證明。

Sachdeva 等人（2024）直接研究 data-efficient LLM pre-training，顯示資料選擇與覆蓋策略可以在大幅減少訓練資料時維持甚至改善部分模型表現；Zhao 等人（2025）則在 continuous-time reinforcement learning 中同時研究 sample efficiency 與 computational efficiency，並提供形式上的 sample-complexity 分析。這些工作處理的是可測量的資料與計算效率。本文不與其競爭，而聚焦於更前一層的判定問題：當既有內容已經成立並可進入後續學習時，新能力的形成是否必須把既有內容全部重新建立一次。

TRT 4.0 已經區分最低必要數量與實際存在總量，也允許表示重新進入後續生成、指定結構在非同一位置重新成立，並限制不同判定層級之間不能無條件轉移。因此，本研究檢查這些既有關係能否對 learning efficiency 提供一個不直接等同於樣本數或算力的理論描述。

二、研究目的

- 以 TRT 4.0 區分「新增成立」與「既有內容全部重新成立」，建立人工智慧學習效率的理論接口。
- 說明 Rep/Enter、Iso、最低數量、Necessary Level 與 Non-Closure 如何共同限制對學習效率的跨領域推論。
- 明確區分 TRT 的最低必要差異數量與機器學習的 sample complexity、compute complexity、memory requirement 及 scaling law。
- 區分能力重用、結構重現、持續學習中的保留，以及真正的工程資源節省。
- 建立後續可操作化的研究問題，而不提前宣稱 TRT 能降低資料量或算力。

三、研究問題

RQ1：既有表示可重新進入後續生成時，新能力的成立是否必須將既有成立內容全部重新建立？

RQ2：TRT 4.0 的最低數量命題能否用於區分「最低必要成立」與「實際資源總量」，而不被誤讀為單一樣本或最低算力命題？

RQ3：結構同型與表示再進入如何描述既有能力的可重用性，而不把重用本身等同於已證明的 data/compute efficiency？

RQ4：Necessary Level 與 Non-Closure 對「更多資料必然更有效」「既有能力必須全部重學」或「找到一個高效表示即可封閉後續學習」等推論形成何種邊界？

四、理論與外部文獻背景

4.1 外部 Learning Efficiency 文獻

Schmidt 等人（2026）以 constraint-centric 視角統整 LLM 訓練中的 data efficiency、memory efficiency 與 compute budget，指出效率不是單一指標，而是多種有限資源下的配置問題。Luo 等人（2025）聚焦 data-efficient LLM post-training，將資料選擇、資料品質、合成資料、資料蒸餾與壓縮等視為提高資料利用效率的重要路徑。

Sachdeva 等人（2024）以資料選擇研究 LLM 預訓練的資料效率，實驗顯示在其設定下可以捨棄大量原始資料仍維持或改善表現。Zhao 等人（2025）則提供 reinforcement learning 中 sample 與 computational efficiency 的演算法與理論結果。上述研究共同顯示，learning efficiency 必須透過明確資源指標、任務設定與經驗或形式結果來判定。本文只使用這些文獻固定 AI 問題背景，不以其證明 TRT。

4.2 TRT 4.0 的直接理論來源

本研究直接使用 TRT 4.0。TRT 4.0 完整承接其前置理論鏈，但不新增底層生成來源。與本篇最直接相關的既有關係包括：Rep/Enter 所表示的表示形成與再進入、Iso 所表示的指定結構同型、最低數量命題所限定的最低必要差異數量、Necessary Level 所限定的判定位置，以及 Non-Closure 所保留的後續生成可能。

$$\begin{aligned} & \text{Rep}(a,r) \wedge \text{Enter}(r,z) \\ & \text{Iso}_{\{\kappa_s\}}(x,y) \wedge \text{NonId}_{\{\kappa_p\}}(x,y) \\ & N_{\min}^{\text{TRT}} = 1 \\ & P_{\{\kappa_a\}} \not\equiv P_{\{\kappa_b\}} \quad (\kappa_a \neq \kappa_b) \end{aligned}$$

其中 $N_{\min}^{\text{TRT}} = 1$ 只表示：一個已成立的差異足以承載其既已成立的非同一關係，第二個差異不是同一非同一成立的最低必要條件。它不表示一個樣本、一個 token、一個參數、一個 batch、一個訓練步驟或一個 FLOP 足以完成 AI 學習。

4.3 本研究的獨立問題

主流 learning-efficiency 研究通常問「如何以更少資源達到指定性能」。本文不直接回答 how-to，而先問「新的能力成立時，哪些內容真的必須新增成立」。如果既有表示可以再進入、既有結構可以在非同一位置重新成立，那麼「新能力形成」與「全部既有內容重新建立」在理論上不是同一判定。

這個區分本身不產生資源節省。只有當後續工程研究把「可重用的既有成立」操作化，並證明其確實減少資料、計算、記憶體、時間或能耗時，才可提升為 **learning-efficiency** 的經驗結果。

4.4 TRT—AI Learning Efficiency 理論接口

TRT 關係	在 AI 學習效率中的理論意義	不直接指定
Gen(x,y)	新的學習位置可以成立；新增能力具有自己的生成位置。	特定 optimizer、training loop 或資料流程。
NonId_{k_p}(x,y)	新學習位置與既有位置非同一；重用不等於回到原位置。	checkpoint 差異、時間戳或向量距離。
Iso_k(x,y)	既有指定結構可在新位置重新成立。	零成本複製、權重完全不變或一定節省 FLOPs。
Rep(a,r)	既有內容可形成表示供後續使用。	embedding、tensor、cache 或特定模型層。
Enter(r,z)	既有表示可以重新進入後續生成。	retrieval、replay、adapter、prompt 或 cache 的固定機制。
$N_{\min}^{\text{TRT}} = 1$	最低必要差異數量與實際存在差異總量可區分。	一筆資料、一個 token 或最低計算量。
$P_{\{k_a\}} \not\Rightarrow P_{\{k_b\}}$	理論最低必要成立不能直接轉譯成工程最低資源需求。	sample complexity、FLOP bound 或 scaling law。
Joint/Agg	多項既有關係可被共同承載而不互相取代。	model merging、parameter sharing 或 memory bank。
Non-Closure	既有表示可重用，但不封閉後續新學習與新差異。	找到一次有效表示後即可停止所有後續學習。

最低判定邊界是：不得把 TRT 的最低數量命題直接轉譯成 AI 的最低樣本量或最低算力；不得把表示再進入直接宣稱為資源節省；不得把結構重現直接等同於免費學習；也不得因某種重用方法有效，就把它提升為所有任務與資源條件下的普遍效率規則。

五、研究方法

本研究採理論分析、概念分解、近期文獻對照與跨領域映射。分析程序包括：（1）以近期 **learning-efficiency** 文獻固定資料、記憶體與計算效率的實際研究問題；（2）辨識 TRT 4.0 中與既有表示再進入、結構重現、最低數量及非封閉直接相關的既有關係；（3）檢查映射是否維持 TRT 原始判定方向與層級；（4）區分理論最低必要成立與工程資源最低量；（5）以支持案例、反例與失效條件限制本文主張。

本研究不是系統性文獻回顧，也沒有進行模型訓練、資料集實驗、FLOP 或能耗測量、記憶體 profiling、統計推論、新的 sample-complexity 證明或 scaling-law 推導。

六、研究材料、資料與證據來源

本研究使用三類材料。第一類為 2024–2026 年 learning efficiency、data-efficient training 與 sample/computational efficiency 的外部研究；第二類為 TRT 4.0 正式理論文本；第三類為本研究在前兩類材料之間形成的跨領域分析。外部文獻負責建立 AI 學習效率問題與現行測量方式；TRT 4.0 提供直接理論關係；本文的貢獻則是建立「新增成立是否要求全部重建」的理論表述。

七、主要分析

7.1 新增能力不等於全部重新成立

如果既有內容 a 已形成表示 r ，且 r 可以重新進入後續生成 z ，則後續新能力的成立至少在理論上不必被描述成「所有既有內容從零重新生成」。TRT 的 Enter 允許既有表示再次參與後續生成，而 Non-Identity 保留新舊生成位置的差異。

$$\text{Rep}(a,r) \wedge \text{Enter}(r,z)$$

因此本文提出：新增成立與全部重建不是同一判定。這是理論上的非同一，不是資源節省的經驗結論。

7.2 重用不等於同一位置回返

既有表示被再次使用，不代表系統返回原生成位置。新位置仍保持 NonId；指定結構若再次成立，可由 Iso 描述。這使「重用」與「複製原狀」分離。

$$\text{Iso}_{\{\kappa_s\}}(x,y) \wedge \text{NonId}_{\{\kappa_p\}}(x,y)$$

因此，能力重用可以伴隨新位置、新差異與新表示。Learning efficiency 若未來被操作化，不應把「重用」誤解成新舊案例或模型狀態完全相同。

7.3 最低數量不是最低資料量

第六篇最重要的邊界是 $N_{\min}^{\text{TRT}} = 1$ 的使用。TRT 3.0/4.0 的最低數量命題只處理已成立非同一所需的最低差異數量。它沒有提供 AI 學習所需的最低樣本數、token 數、參數數、梯度步數或 FLOPs。

$$N_{\min}^{\text{TRT}} = 1 \not\Rightarrow N_{\text{samples}} = 1$$

$$N_{\min}^{\text{TRT}} = 1 \not\Rightarrow \text{Compute}_{\min} = 1$$

所以本文不能由 TRT 推出 few-shot、one-shot 或 zero-shot learning 的資源保證。任何此類結論都需要另外的模型、資料、任務與實驗證據。

7.4 最低必要成立與實際總量

TRT 4.0 區分最低必要量與實際存在總量。跨領域映射到 **learning efficiency**，可形成一個研究問題：某項新能力真正需要新增哪些判定，而哪些內容只是已存在、可再進入或可共同承載。這個問題可以引導後續操作化，但目前不能直接換算成節省百分比。

因此：實際使用很多資料 $\neq$ 每一筆資料都是該能力成立的理論最低必要條件；反之，理論上某些既有成立可被重用 $\neq$ 工程上必然可以刪除相同比例資料。

7.5 Rep/Enter 與資源重用的邊界

表示再進入提供「既有內容可以參與後續生成」的理論位置。實際 AI 可以透過 **pretraining**、**transfer learning**、**retrieval**、**cache**、**adapter**、**distillation** 或其他方式重用既有能力，但 TRT 不指定其中任何一種機制。

只有當某個實作在相同任務與性能標準下，實際降低資料、計算、記憶體、時間或能耗，才能稱為工程上的效率提升。**Rep/Enter** 本身不提供這個比較結果。

7.6 Necessary Level：效率指標不可互相偷渡

Learning efficiency 包含多種不同指標。資料更少不自動等於計算更少；參數更少不自動等於訓練時間更短；FLOPs 更少也不自動等於能源消耗更低。TRT 4.0 的 **Necessary Level** 可用來限制這種跨指標推論。

$$P_{\{\kappa_{\text{data}}\}} \not\Rightarrow P_{\{\kappa_{\text{compute}}\}} \not\Rightarrow P_{\{\kappa_{\text{memory}}\}}$$

此處 κ_{data} 、 κ_{compute} 、 κ_{memory} 是本文為跨領域分析所使用的判定標記，不是 TRT 4.0 原有固定工程變數。

7.7 Non-Closure：一次高效不封閉所有後續條件

即使某種資料選擇或表示重用在特定任務上有效，也不能僅由此取得所有後續任務、模型規模或資源條件下必然有效的資格。近期效率文獻本身也顯示不同資源限制與任務設定存在 **trade-off**。TRT 的 **Non-Closure** 在本文中提供的是判定邊界：局部效率成立不封閉所有後續生成。

八、研究結果

結果	研究判定	TRT 依據	狀態	證據層級
R1	新能力的成立不等於既有成立內容全部重新建立。	Rep/Enter；Non-Identity。	框架內成立	理論映射

R2	既有指定結構可以在新位置重新成立，而不要求生成位置同一。	$Iso \wedge NonId$ 。	成立	TRT 內部相容性
R3	TRT 最低數量命題不能推出最低樣本量、最低 token 數或最低算力。	$N_{min}^{TRT}=1$; Necessary Level 。	不成立之跨層推論	邊界判定
R4	資料效率、計算效率與記憶體效率應分別判定，不能自動互推。	Necessary Level 。	可成立的限制	跨領域映射
R5	既有表示可再進入後續生成，但不保證實際節省任何資源。	Rep/Enter；證據邊界。	條件成立	理論映射
R6	特定任務上的效率成立不封閉所有後續任務與資源條件。	Non-Closure 。	成立	理論推論
R7	本研究不能證明 TRT 能提高實際模型的 sample、compute、memory 或 energy efficiency 。	尚無操作化與實驗。	未證明	研究限制

九、支持案例、反例與邊界案例

9.1 支持性概念案例：預訓練後的任務學習

假設模型已形成一組可用於多個任務的既有表示，後續只需建立與新任務相關的新增判定，而不是重新從原始資料建立全部既有表示。本文可以把這種情境描述為既有表示再進入後續生成，而新任務形成新的成立。此案例只說明理論關係，不證明任何特定 fine-tuning 方法必然更省資料或算力。

9.2 反例：重用反而增加成本

某些系統雖然重用既有模型或表示，但 retrieval、routing、memory management 或額外推論步驟可能增加總計算與記憶體成本。若本文把「表示再進入」直接等同於「資源更省」，這類案例即可反駁該推論。因此 Rep/Enter 只能建立可重用性接口，不能建立效率結果。

9.3 邊界案例：資料少但計算更多

一種方法可能使用較少人工標註資料，卻以大量合成資料生成、搜尋或推理計算換取性能。此時 data efficiency 可能提高，但 compute efficiency 未必提高。這正是 Necessary Level 在第六篇中的重要用途：不同效率指標不能被共同稱為「效率」後就視為同一。

9.4 $N_{min}^{TRT} = 1$ 的反例邊界

若實驗顯示某項能力需要數百萬樣本才能達到指定誤差，這不反駁 TRT 的 $N_{min}^{TRT} = 1$ ，因為兩者判定對象不同；同樣地， $N_{min}^{TRT} = 1$ 也不能反駁該 sample-complexity 結果。若本文把兩者混為同一數量命題，則第六篇理論映射失效。

十、討論

本研究的主要轉換，是把 **Learning Efficiency** 的一部分問題從「怎麼用更少資源」往前拆成「新的能力成立時，究竟哪些成立必須新增」。主流研究仍負責回答資料、計算、記憶體、時間與能源是否真的下降；**TRT 4.0** 則提供一個更基本的判定區分：既有內容可重新進入，新增成立不等於全部重建，而最低必要成立不能被換算成工程最低資源。

這個位置使第六篇不需要宣稱 **TRT** 是效率演算法。它的研究價值在於防止三種跨層誤讀：第一，把 $N_{\min}^{\text{TRT}} = 1$ 誤讀為 **one-shot learning**；第二，把表示重用誤讀為必然節省資源；第三，把某一效率指標成立誤讀為所有效率指標共同成立。

近期外部研究顯示，資料選擇、記憶體限制與計算預算之間存在實際 **trade-off**，也有工作能在特定設定下以較少資料或較少更新取得相近性能。這些結果提供後續操作化的經驗場域，但本文仍不把任何外部效率結果視為 **TRT** 的實證證明。

十一、研究限制

- 本研究為跨領域理論映射，未進行任何模型訓練或效率 **benchmark**。
- 尚未將「新增成立」「既有成立再進入」或「最低必要成立」操作化為可測量的 **AI** 變數。
- 本文不提出新的 **data selection**、**compression**、**PEFT**、**distillation**、**optimizer**、**cache**、**routing** 或 **hardware** 方法。
- 本文不建立 **sample complexity**、**compute complexity**、**memory complexity**、**energy bound** 或 **scaling law**。
- $N_{\min}^{\text{TRT}} = 1$ 不能被解讀為一筆資料、一個 **token**、一個步驟或固定最低算力足以學會能力。
- 表示再進入不等於資源節省；重用既有模型也可能增加其他成本。
- 本文使用近期代表性文獻建立背景與邊界，不構成完整的 **learning-efficiency** 系統性回顧。

十二、可反駁性與結果失效條件

- 若 **TRT** 正式理論未允許既有表示重新進入後續生成，本文以 **Rep/Enter** 描述可重用性的部分失去基礎。
- 若 **TRT** 的最低數量命題被正式限定為可直接對應外部資源數量，本文目前對 $N_{\min}^{\text{TRT}}$ 與 **sample/compute quantity** 的分離需要修正。
- 若後續操作化顯示任何新能力的形成在所選模型定義下都必須重新建立全部既有內容，則「新增成立 $\neq$ 全部重建」在該操作化中的適用性失敗。

- 若無法建立「既有成立再進入」與任何可觀察的模型重用行為之間的測量對應，本文只能維持概念性理論解釋。
- 若後續研究證明本文所區分的新增成立與全部重建在相關 AI 設定中不可操作化區分，則第六篇的獨立經驗研究價值應降低。

十三、後續研究方向

- 建立「新增成立量」與「既有內容再使用」的操作化定義，並與實際資料量、FLOPs、記憶體與訓練時間分開測量。
- 設計 ablation：比較從零訓練、完整重訓、部分重用與表示再使用時的性能—資源曲線。
- 檢驗不同效率指標之間是否存在 Necessary Level 所要求的判定分離，例如 data-efficient 但 compute-expensive 的方法。
- 比較 TRT 的「新增成立 $\neq$ 全部重建」與 transfer learning、PEFT、distillation、retrieval、continual pretraining 等方法的可操作化接口。
- 研究哪些情況下既有表示的再進入真正形成可測量的邊際資源節省，哪些情況反而增加系統成本。
- 建立反例集，測試「重用很多但不高效」與「幾乎不重用但仍高效」的情況，以限制 TRT 映射的適用範圍。

十四、結論

本研究以 TRT 4.0 作為直接理論來源，對人工智慧 Learning Efficiency 建立第六篇獨立跨領域理論分析。核心結果是：當既有結構與表示已經成立並可重新進入後續生成時，新的能力或判定在新位置成立，不等於全部既有內容都必須再次作為新的成立內容。本文因此提出最低理論表述：新增成立，不等於全部重建。

同時，TRT 4.0 的最低數量命題不能被跨層轉譯為 AI 的最低樣本量或最低算力。 $N_{\min}^{\text{TRT}} = 1$ 處理的是已成立非同一所需的最低差異數量，不是 one-shot learning、sample complexity 或 compute bound。Rep/Enter 提供既有表示可再進入的理論接口，也不等於實際資源節省。

因此，人工智慧中的資料、計算、記憶體、時間與能源效率仍須由具體模型、任務、資源條件與實驗測量建立；本文所提出的理論區分，只限定新增成立、既有成立再進入與最低必要成立之間的判定關係。只有後續操作化與實驗證明資源確實下降時，才能形成 AI 效率的經驗主張。

最低理論表述：新增成立，不等於全部重建。

參考文獻

非同一（ Σ - Ω ）. (2026). 《時間還原理論 4.0：非同一——高階總和表示理論》 [Time Restoration Theory 4.0: Non-Identity — Theory of Higher-Order Aggregate Representation]. 正式理論研究稿. DOI: 10.5281/zenodo.22430773.

Schmidt, V., Nguyen, H. H., Jung, C. D., Salehi, S., & Schmeink, A. (2026). Unifying Data, Memory, and Compute Efficiency in LLM Training: A Survey. IEEE Transactions on Artificial Intelligence, 1–21. DOI: 10.1109/TAI.2026.3702625.

Luo, J., Wu, B., Luo, X., Xiao, Z., Jin, Y., Tu, R.-C., Yin, N., Wang, Y., Yuan, J., Ju, W., & Zhang, M. (2025). A Survey on Efficient Large Language Model Training: From Data-centric Perspectives. Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), 30904–30920. DOI: 10.18653/v1/2025.acl-long.1493.

Sachdeva, N., Coleman, B., Kang, W.-C., Ni, J., Hong, L., Chi, E. H., Caverlee, J., McAuley, J., & Cheng, D. Z. (2024). How to Train Data-Efficient LLMs. arXiv:2402.09668.

Zhao, R., Yu, Y., Zhu, A. Y., Yang, C., & Zhou, D. (2025). Sample and Computationally Efficient Continuous-Time Reinforcement Learning with General Function Approximation. Proceedings of the Forty-first Conference on Uncertainty in Artificial Intelligence, PMLR 286, 5030–5057.

建議引用格式 / Suggested Citation

非同一（ Σ - Ω ）. (2026). 《新增成立的必要邊界：時間還原理論 4.0 對人工智慧學習效率問題的理論闡述》 [Necessary Boundaries of New Establishment: A Time Restoration Theory 4.0 Account of Learning Efficiency in Artificial Intelligence]. 正式跨領域理論研究稿. DOI: 10.5281/zenodo.22670346

Non-Identity (Σ - Ω). (2026). Necessary Boundaries of New Establishment: A Time Restoration Theory 4.0 Account of Learning Efficiency in Artificial Intelligence. Formal Cross-Disciplinary Theoretical Research Manuscript. DOI: 10.5281/zenodo.22670346