

# 對齊與控制的判定邊界

時間還原理論 4.0 對人工智慧對齊與控制問題的理論闡述

## **Judgment Boundaries of Alignment and Control**

*A Time Restoration Theory 4.0 Account of Alignment and Control in Artificial Intelligence*

作者：非同一（ $\Sigma$ - $\Omega$ ）

2026 正式跨領域理論研究稿

DOI：10.5281/zenodo.22673757

## 摘要

高能力人工智慧的對齊與控制問題，通常涉及如何使系統的行為、偏好反應、安全限制與決策結果符合人類意圖，以及如何取得足以支持相關判定的證據。本文以時間還原理論 4.0（TRT 4.0）的非同一、必要層級與非封閉命題為直接理論來源，提出一項跨領域理論分析：某一對齊判定成立，不等於其他對齊判定自動成立；多項對齊要求可以共同成立或共同表示，但不因此成為同一判定；局部測試、特定任務或既有控制條件的成立，也不自動封閉未來生成位置上的行為與風險。

本文不主張 TRT 能直接使 AI 對齊人類，也不提供新的訓練演算法、控制機制或安全保證。本文處理的是更前置的判定問題：當研究者或部署者宣稱一個 AI「已對齊」「可控」或「符合人類意圖」時，現有證據究竟支持哪一個判定位置，以及哪些更強的判定仍需要另外建立。本文將此界線稱為「對齊與控制的判定邊界」。

本文並以 instruction following、human-preference alignment、個人化對齊與 guideline following 等外部研究作為 AI 問題背景。外部文獻用於建立問題域與經驗現象，不作為 TRT 4.0 的理論證明。

關鍵詞：時間還原理論 4.0；非同一；人工智慧對齊；人工智慧控制；必要層級；判定邊界；非封閉；人類意圖

## Abstract

Alignment and control of highly capable AI concern whether system behavior, preference responses, safety constraints, and decision outcomes remain consistent with human intentions, and what evidence is sufficient to support such judgments. Using Time Restoration Theory 4.0 (TRT 4.0) as its sole TRT theoretical source, this paper develops a cross-disciplinary account centered on Non-Identity, Necessary Level, and Non-Closure. The central claim is that the establishment of one alignment judgment does not automatically establish another; multiple alignment requirements may be jointly satisfied or represented without becoming identical judgments; and local test success or control conditions do not by themselves close future generative positions.

The paper does not claim that TRT directly aligns AI systems, supplies an alignment algorithm, or guarantees safety. Its contribution is a judgment framework for asking what a given body of alignment evidence actually licenses us to conclude, and where that license stops.

## 一、背景

人工智慧對齊研究關心如何使 AI 系統的行為與人類意圖、偏好與價值保持適當關係。現有研究包含 instruction following、preference alignment、安全訓練、可控性、評估與治理等不同面向。這些面向彼此相關，但並非天然等同。

例如，一個模型可以在指定測試中遵循指令；另一個判定則可能要求它在不同情境下仍遵守安全規則；更強的判定又可能涉及偏好、價值或控制能力。本文不預先把這些內容壓縮成單一「對齊」變項，而是追問：每一項證據究竟支持哪一項判定。

## 二、研究目的

- 建立 TRT 4.0 與 AI Alignment & Control 之間的跨領域理論接口。
- 區分「某一對齊判定成立」與「整體對齊成立」之間的推論距離。
- 分析多項對齊要求共同成立時，為何共同性不等於判定同一或角色同一。
- 分析局部控制、測試成功與既有安全條件為何不自動封閉未來行為。
- 提出可被 AI 實證研究操作化與反駁的判定邊界。

## 三、研究問題

RQ1：某一種對齊證據成立，是否足以使其他對齊判定自動成立？

RQ2：多種對齊目標或控制要求共同存在，是否因此成為同一判定或可互相取代？

RQ3：在特定測試、任務或部署條件下的安全表現，是否足以封閉其他情境與未來生成位置？

RQ4：TRT 4.0 能對 AI Alignment & Control 提供什麼判定限制，而不越界成為 AI 工程機制？

## 四、理論與外部文獻背景

### 4.1 TRT 4.0 的直接理論來源

本文只以《時間還原理論 4.0：非同一——高階總和表示理論》作為 TRT 理論來源。TRT 4.0 已完整承接原始 TRT、本體數學形式化、TRT 2.0 與 TRT 3.0；本文不另行建立或修改其底層理論。

$$P_{\{\kappa_a\}} \not\Rightarrow P_{\{\kappa_b\}} \quad (\kappa_a \neq \kappa_b)$$

必要層級命題指出：某一判定面向上的成立，不自動取得另一判定面向上的成立位置。TRT 4.0 同時指出：共同成立不等於判定同一；共同承載不等於角色同一；共同表示不等於本體同一。

$$\text{Joint}(P_1, \dots, P_n; G) \not\Rightarrow P_i = P_j$$

非封閉命題則限制局部成立的效力：局部成立、局部中止、目標或高階表示，都不自動取得封閉全部後續生成的地位。

## 4.2 AI Alignment & Control 的外部問題域

外部 AI 文獻顯示，alignment 並非單一工程目標。研究可分別處理指令遵循、人類偏好、價值、安全、可控性、規則遵循、分布轉移與評估等問題。這些研究提供本文的問題背景與案例來源，但不證明 TRT。

Instruction-following 研究將遵循任務指令本身視為可獨立研究與評估的能力；偏好對齊研究則處理人類偏好資料與模型行為之間的關係；近期 guideline-following benchmark 亦把規則遵循、規則更新的穩健性與人類偏好對齊分成不同評估面向。這些區分使「對齊」是否應被視為單一判定成為可分析的問題。

## 五、TRT—AI Alignment & Control 理論接口

| TRT 4.0 理論位置 | 基本關係                                      | AI 對齊與控制接口                      | 判定邊界                  |
|--------------|-------------------------------------------|---------------------------------|-----------------------|
| 必要層級         | $P_{\{k_a\}} \not\Rightarrow P_{\{k_b\}}$ | 不同對齊證據分屬不同判定位置                  | 一項成立不自動授權另一項成立        |
| 非同一          | 共同成立 $\neq$ 判定同一                          | 多種 alignment requirements 可共同成立 | 共同滿足不等於要求本身相同         |
| Joint        | $\text{Joint}(P_1, \dots, P_n; G)$        | 多項對齊／控制條件共同進入同一系統評估             | 共同位置不提供 $P_i = P_j$   |
| Agg          | $\text{Agg}(\dots, \Gamma, r^*)$          | 綜合安全評估或高階對齊表示                   | 綜合分數／表示不等於底層判定同一      |
| 表示 $\neq$ 結構 | $\text{Rep}(a, r)$                        | 對偏好、規則、價值或意圖的模型表示               | 表示內容不因此與被表示者本體同一      |
| 非封閉          | 局部成立 $\not\Rightarrow$ 整體封閉               | 特定 benchmark、任務或部署條件下的成功        | 不自動封閉未知情境與後續行為        |
| Enter        | $\text{Enter}(r, z)$                      | 既有規則／偏好表示重新進入後續決策               | 重新進入不保證每一新位置都取得相同對齊判定 |

## 六、研究方法

本文採理論映射與判定邊界分析。第一步，固定 TRT 4.0 中已成立的理論命題，不將 AI 概念回寫為 TRT 底層謂詞。第二步，從 AI alignment 文獻辨識可區分的判定內容，例如 instruction following、preference alignment、guideline adherence、robustness 與 controllability。第三步，檢查一項證據是否被無條件延伸為另一項判定。第四步，以支持案例、反例與邊界案例檢驗本文提出的跨領域命題是否過強。

本文不把神經網路 hidden states、reward model、policy、loss、RLHF、DPO 或其他工程元件直接等同於 TRT 的 Rep、Joint、Agg、G 或判定面向。任何此類對應都需要另外操作化。

## 七、材料、資料與證據來源

本文材料分成兩類。第一類是 TRT 4.0 正式理論文本，提供本文唯一 TRT 理論來源。第二類是外部 AI alignment 與 instruction-following 文獻，用於建立研究問題、實證現象與反例。本文不進行模型訓練、紅隊測試、偏好資料蒐集或控制實驗，因此所有工程效果主張均保持為待驗證狀態。

## 八、主要分析

### 8.1 對齊不是一個可以無條件壓縮的判定

「AI 已對齊」在實際研究中可能承載多個不同內容。若某模型在指定指令遵循測試取得高分，這首先建立的是該測試與其操作定義所支持的判定。若要進一步判定模型在另一種安全要求、偏好要求或控制條件上成立，必須另外建立相應依據。

$$\text{Alignment}_{\{\kappa_a\}}(M) \not\Rightarrow \text{Alignment}_{\{\kappa_b\}}(M) \quad \text{when } \kappa_a \neq \kappa_b$$

此式是本文的跨領域表示，不是 TRT 4.0 原始形式謂詞。它只把 Necessary Level 映射到 alignment 判定問題。

### 8.2 行為符合不自動取得更強判定

可觀察行為符合要求，可以構成重要證據，但證據的成立範圍必須由測試設計、條件與操作定義決定。TRT 不據此宣稱存在或不存在某種不可觀察的「內部目標」。TRT 能說的是：若第二個判定的內容超出第一個判定已建立的範圍，第一個成立本身不足以自動建立第二個。

### 8.3 多目標共同成立不等於目標同一

AI 系統可能同時被要求 **helpful**、**safe**、**truthful**、**instruction-following**、**preference-sensitive** 或遵循特定規則。這些要求可以共同進入訓練、評估或部署，但共同存在不表示它們具有相同判定功能，也不表示改善其中一項必然改善另一項。

$$\text{Joint}(A_1, A_2, \dots, A_n) \not\Rightarrow A_i = A_j$$

### 8.4 綜合分數不取消底層非同一

實務上可以建立單一 **dashboard**、綜合安全報告或 **aggregate score**。TRT 4.0 的 **Agg** 接口提醒：高階共同表示可以有效，但它不因此把被共同承載的不同判定改寫成同一。若一個綜合分數上升，仍需追問究竟是哪一項底層判定發生改變。

### 8.5 控制成立也有判定位置

「可控」同樣不能作為無限定詞。人工干預能力、規則約束、權限限制、停止機制、監督有效性與不同部署情境中的控制表現，可以是不同判定。某一控制機制存在，不自動推出所有控制要求均已成立。

因此本文對 **Control** 的最低主張是：控制證據必須保留其判定位置。TRT 不提供控制技術本身。

### 8.6 非封閉：今天通過不等於未來封閉

在指定資料集、任務或部署條件下通過對齊測試，是一個可以成立的局部結果；但該結果不自動取得封閉所有未來生成位置的資格。新的任務、規則更新、使用者需求、工具權限或環境改變，都可能形成新的判定位置。

$$\text{LocalAlignmentSuccess} \not\Rightarrow \text{AlignmentClosure}$$

此式同樣是本文的 **AI** 領域映射，而非 TRT 4.0 原始謂詞。它表達 **Non-Closure** 在 **alignment** 問題上的限制。

## 九、研究結果

| 結果 | 理論判定          | AI 領域含義                                      |
|----|---------------|----------------------------------------------|
| R1 | 單一對齊判定不自動跨層轉移 | 某一測試／要求成立，不自動建立另一不同要求                        |
| R2 | 共同對齊不等於判定同一   | 多項 <b>alignment requirements</b> 可共同成立而保持非同一 |
| R3 | 綜合表示不等於整體同一   | <b>aggregate evaluation</b> 不取消底層判           |

|    |              |                                                               |
|----|--------------|---------------------------------------------------------------|
|    |              | 定差異                                                           |
| R4 | 控制證據具有局部判定位置 | 一項 <b>control mechanism</b> 不等於所有 <b>controllability</b> 判定成立 |
| R5 | 對齊結果保持非封閉    | 局部成功不構成所有未來情境的封閉保證                                            |

## 十、支持案例、反例與邊界案例

### 10.1 支持案例：指令遵循與偏好對齊可被分開研究

現有研究把 **instruction following** 與 **human-preference alignment** 作為可區分的訓練與評估目標。這支持本文至少在問題設定上區分不同判定位置的必要性，但不構成 TRT 的證明。

### 10.2 支持案例：規則遵循可拆成多項評估

GuideBench 將多樣規則遵循、規則更新的穩健性與人類偏好對齊分別評估。這顯示即使同屬廣義 **alignment/guideline-following** 問題，實證研究仍可能需要多個判定維度。

### 10.3 反例：不同對齊目標可能高度相關

若實證顯示某些對齊指標在特定條件下高度相關，這不直接反駁本文。TRT 的主張不是「不同判定永遠無關」，而是「相關或共同成立本身不提供判定同一」。若研究能建立可靠的跨判定推論規則，則跨層推論可以在新增依據下成立。

### 10.4 反例：單一綜合指標可能具有高度預測力

若一個 **aggregate score** 能穩定預測多項安全結果，它可以具有工程價值。本文並不禁止高階總和表示；它只拒絕由「高階表示有效」直接推出「底層判定已成為同一」。

### 10.5 邊界案例：行為證據與不可觀察內部狀態

本文不從外部行為直接推論模型具有某種特定內部目標，也不以 TRT 判定其真偽。若研究問題涉及內部機制，需要 **mechanistic interpretability**、**causal intervention** 或其他獨立方法建立證據。

## 十一、討論

本文的主要價值不是提出另一種 **alignment training** 方法，而是限制 **alignment claim** 的推論幅度。當「對齊」被用作高階總稱時，**TRT 4.0** 提醒研究者保留底層判定的非同一：可以共同，但不能只因共同就互相取代。

這一框架也使「控制」從單一標籤轉成帶有判定位置的主張。控制機制是否存在、是否可用、是否在特定條件有效、是否能處理新的行為位置，是可以分開建立的問題。

因此，**TRT** 在此不回答「如何確保 **AI** 一定符合人類意圖」，而是回答一個更前置的問題：現有證據究竟足以讓我們說到哪裡。

## 十二、研究限制

- 本文是跨領域理論研究，不是 **alignment** 工程方法。
- 本文沒有建立 **TRT** 謂詞與神經網路內部變量的一一對應。
- 本文沒有證明任何現有 **alignment benchmark** 足以或不足以代表整體 **alignment**；具體效度需由實證研究決定。
- **Necessary Level** 限制的是無條件跨層轉移，不是否定所有跨層推論。若額外橋接條件被建立，推論可以成立。
- **Non-Closure** 不等於 **AI** 必然失控，也不等於未來一定出現新風險；它只否定由局部成立直接推出整體封閉。
- 本文不解決『人類意圖』本身如何定義、聚合、衝突協調或正當化。

## 十三、可反駁性與失效條件

本文的跨領域主張若要取得更強地位，必須接受操作化檢驗。以下情況會削弱或使特定映射失效：

- 若某研究域能嚴格證明兩個被本文區分的 **alignment** 判定在其操作定義下實際為同一判定，則該特定區分不應被保留。
- 若建立了可驗證且穩定的橋接規則，使  $\kappa_a$  的成立在指定條件下充分推出  $\kappa_b$ ，則不能再以 **Necessary Level** 阻止該有條件推論。
- 若某 **aggregate measure** 的定義本身就是底層各判定的完整邏輯等價表示，則本文不能僅以『**aggregate**』名稱否定其效力。



- 若實證操作無法區分本文提出的不同判定位置，則本文目前只能維持概念分析地位，不能宣稱工程效益。

## 十四、後續研究方向

- 建立 **alignment judgment taxonomy**，明確區分指令遵循、偏好、安全、規則、控制等操作性判定。
- 設計跨判定 **transfer test**，檢查一項 **alignment success** 對另一項判定究竟具有多少可驗證推論力。
- 研究 **aggregate alignment score** 與底層判定之間的資訊損失與可追溯性。
- 在規則更新、工具使用與分布轉移情境下測試 **Non-Closure** 映射。
- 以 **causal intervention** 或 **mechanistic analysis** 檢驗行為層證據與內部機制判定之間是否存在可建立的橋接條件。

## 十五、結論

本文以 **TRT 4.0** 的非同一、必要層級與非封閉命題，對 **AI Alignment & Control** 提出一項跨領域理論判定：某一對齊判定成立，不等於其他對齊判定自動成立。多項對齊與控制要求可以共同成立、共同承載或共同進入高階評估，但共同性本身不使它們取得彼此的判定位置。

因此，本文不把「對齊」視為只要一項證據成立即可無限制擴張的單一標籤。局部測試成功應被承認，但其效力不能超出已建立的判定位置；新的情境與後續行為仍需新的成立依據。

本文的最低理論表述是：

某一對齊判定成立，不等於其他對齊判定自動成立。

更完整地說：對齊可以共同成立，但共同成立不取消判定非同一；控制可以局部成立，但局部成立不封閉全部後續生成。

## 參考文獻

非同一 ( $\Sigma\text{-}\Omega$ ) . (2026). 《時間還原理論 4.0：非同一——高階總和表示理論》 [Time Restoration Theory 4.0: Non-Identity — Theory of Higher-Order Aggregate Representation]. 正式理論研究稿. DOI: 10.5281/zenodo.22430773.

Ji, J., Qiu, T., Chen, B., et al. (2023). AI Alignment: A Comprehensive Survey. arXiv:2310.19852.

Lou, R., Zhang, K., & Yin, W. (2024). Large Language Model Instruction Following: A Survey of Progresses and Challenges. *Computational Linguistics*, 50(3), 1053–1095. DOI: 10.1162/coli\_a\_00523.

Wang, C., Zhou, H., Chang, K., et al. (2024). Hybrid Alignment Training for Large Language Models. *Findings of ACL 2024*, 11389–11403. DOI: 10.18653/v1/2024.findings-acl.676.

Guan, J., Wu, J., Li, J.-N., Cheng, C., & Wu, W. (2025). A Survey on Personalized Alignment—The Missing Piece for Large Language Models in Real-World Applications. *Findings of ACL 2025*, 5313–5333. DOI: 10.18653/v1/2025.findings-acl.277.

Kim, J., Goyal, A., Zhang, A., et al. (2025). A Systematic Examination of Preference Learning through the Lens of Instruction-Following. *NAACL 2025*, 11062–11082. DOI: 10.18653/v1/2025.naacl-long.552.

Diao, S., et al. (2025). GuideBench: Benchmarking Domain-Oriented Guideline Following for LLM Agents. *ACL 2025*, 11361–11399. DOI: 10.18653/v1/2025.acl-long.557.

## 建議引用格式

非同一（ $\Sigma$ - $\Omega$ ）. (2026). 《對齊與控制的判定邊界——時間還原理論 4.0 對人工智慧對齊與控制問題的理論闡述》 [Judgment Boundaries of Alignment and Control: A Time Restoration Theory 4.0 Account of Alignment and Control in Artificial Intelligence]. 正式跨領域理論研究稿. DOI: 10.5281/zenodo.22673757